

Business Understanding

- * faktor apa yang paling mempengaruhi performa akademik siswa?
- * apakah terdapat pola tertentu pada siswa dengan nilai tertinggi?

Import Library

```
In [ ]: import numpy as np
import pandas as pd
from sklearn.preprocessing import MinMaxScaler
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.linear_model import LinearRegression
```

Data Wrangling

Gathering Data

```
In [ ]: student_df =  
pd.read_csv("https://raw.githubusercontent.com/devyti/CAPSTONE-  
PROJECT/refs/heads/main/DATA/student_performance.csv")  
student_df.head()
```

	student_id	age	gender	academic_level	study_hours	self_stu
0	37.57	18.51	Other	High School	7.79	0.34
1	-8.18	18.25	Other	High School	2.32	2.76
2	50.68	22.12	Male	High School	3.69	0.26
3	116.12	17.04	Other	High School	5.78	1.94
4	-12.24	NaN	Other	High School	6.83	2.00

5 rows × 21 columns



Accessing Data

```
In [ ]: student_df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5100 entries, 0 to 5099
Data columns (total 21 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   student_id                           4998 non-null   float64
1   age                                   4998 non-null   float64
2   gender                               5100 non-null   object
3   academic_level                       5100 non-null   object
4   study_hours                          4998 non-null   float64
5   self_study_hours                    5100 non-null   float64
6   online_classes_hours                5100 non-null   float64
7   social_media_hours                  5100 non-null   float64
8   gaming_hours                        5100 non-null   float64
9   sleep_hours                         5100 non-null   float64
10  screen_time_hours                   5100 non-null   float64
11  exercise_minutes                    5100 non-null   float64
12  caffeine_intake_mg                  5100 non-null   float64
13  part_time_job                       5100 non-null   float64
14  upcoming_deadline                   5100 non-null   float64
15  internet_quality                    5100 non-null   object
16  mental_health_score                 5100 non-null   float64
17  focus_index                         5100 non-null   float64
18  burnout_level                       5100 non-null   float64
19  productivity_score                  5100 non-null   float64
20  exam_score                          5100 non-null   float64
dtypes: float64(18), object(3)
memory usage: 836.8+ KB
```

```
In [ ]: print("Jumlah Duplikasi: ", student_df.duplicated().sum())
```

```
Jumlah Duplikasi: 0
```

```
In [ ]: student_df.isnull().sum()
```

	0
student_id	102
age	102
gender	0
academic_level	0
study_hours	102
self_study_hours	0
online_classes_hours	0
social_media_hours	0
gaming_hours	0
sleep_hours	0
screen_time_hours	0
exercise_minutes	0
caffeine_intake_mg	0
part_time_job	0
upcoming_deadline	0
internet_quality	0
mental_health_score	0
focus_index	0
burnout_level	0
productivity_score	0
exam_score	0

dtype: int64

```
In [ ]: student_df.describe()
```

	student_id	age	study_hours	self_study_hours	or
count	4998.000000	4998.000000	4998.000000	5100.000000	51
mean	2546.531505	19.381098	4.633077	2.138906	1.9
std	1473.691202	2.417819	1.958660	1.181717	1.7
min	-126.850000	14.160000	-1.280000	-1.180000	-1
25%	1276.067500	17.370000	3.310000	1.317500	1.7
50%	2549.635000	19.170000	4.660000	2.130000	1.9
75%	3808.680000	21.180000	5.960000	2.940000	2.7
max	5257.140000	25.840000	11.170000	6.360000	5.7

Insight

- Dataset terdiri dari 5000 data siswa
- Tidak ditemukan missing value pada seluruh kolom
- Tidak terdapat data duplikat
- Data terdiri dari variabel numerik dan kategorikal seperti gender dan academic_level
- Variabel target dalam analisis ini adalah exam_score

Cleaning Data

```
In [ ]: # Drop kolom tidak penting / tidak digunakan
student_df = student_df.drop(
    columns=[
        'exercise_minutes',
        'caffeine_intake_mg',
        'part_time_job',
        'upcoming_deadline',
        'student_id',
        'academic_level'
    ]
)
```

```
In [ ]: # 2. Isi null age dengan median
student_df['age'] = student_df['age'].fillna(student_df['age'].median())

# 3. Isi null study_hours dengan median
student_df['study_hours'] =
student_df['study_hours'].fillna(student_df['study_hours'].median())

# Cek ulang null
print(student_df.isnull().sum())
```

```
age          0
gender       0
study_hours  0
self_study_hours  0
online_classes_hours  0
social_media_hours  0
gaming_hours  0
sleep_hours  0
screen_time_hours  0
internet_quality  0
mental_health_score  0
focus_index  0
burnout_level  0
productivity_score  0
exam_score   0
dtype: int64
```

```
In [ ]: student_df.describe()
```

	age	study_hours	self_study_hours	online_classes_hou
count	5100.000000	5100.000000	5100.000000	5100.000000
mean	19.376876	4.633616	2.138906	1.942082
std	2.393696	1.938974	1.181717	1.150659
min	14.160000	-1.280000	-1.180000	-1.230000
25%	17.400000	3.330000	1.317500	1.120000
50%	19.170000	4.660000	2.130000	1.930000
75%	21.140000	5.930000	2.940000	2.700000
max	25.840000	11.170000	6.360000	5.740000

```
In [ ]: # Daftar kolom yang ingin diubah ke integer
kolom_integer = ["age", "mental_health_score", "focus_index",
"burnout_level"]
# Mengubah tipe data float -> integer
student_df[kolom_integer] = student_df[kolom_integer].astype(int)

# Daftar kolom yang ingin diubah ke string
kolom_object = ["gender", "internet_quality"]
# Mengubah tipe data menjadi string
student_df[kolom_object] = student_df[kolom_object].astype("string")

# Cek tipe data
print(student_df.dtypes)
```

```
age                                int64
gender                            string[python]
study_hours                        float64
self_study_hours                   float64
online_classes_hours               float64
social_media_hours                 float64
gaming_hours                       float64
sleep_hours                        float64
screen_time_hours                  float64
internet_quality                   string[python]
mental_health_score                int64
focus_index                       int64
burnout_level                      int64
productivity_score                 float64
exam_score                         float64
dtype: object
```

1. Mengubah nilai minus pada beberapa kolom:

- student_id
- study_hours
- self_study_hours
- online_classes_hours
- social_media_hours
- gaming_hours
- screen_time_hours
- exercise_minutes
- caffeine_intake_mg
- part_time_job
- upcoming_deadline
- mental_health_score
- focus_index
- burnout_level
- productivity_score

2. Membulatkan nilai agar menjadi 2 desimal supaya lebih mudah dibaca

3. Mengubah student_id agar berurutan mulai dari 1

```
In [ ]: # ambil semua kolom numerik
num_cols = student_df.select_dtypes(include="number").columns

# mengecek jumlah nilai negatif sebelum cleaning
negative_values = (student_df[num_cols] < 0).sum()
print("Jumlah nilai negatif sebelum cleaning:")
print(negative_values)

# Bersihkan nilai negatif dengan abs() (kecuali student_id)
student_df[num_cols] = student_df[num_cols].abs()

# cek setelah cleaning
print("\nJumlah nilai negatif setelah cleaning:")
print((student_df[num_cols] < 0).sum())
```

Jumlah nilai negatif sebelum cleaning:

age	0
study_hours	44
self_study_hours	158
online_classes_hours	215
social_media_hours	87
gaming_hours	280
sleep_hours	0
screen_time_hours	2
mental_health_score	0
focus_index	4
burnout_level	62
productivity_score	4
exam_score	0
dtype: int64	

Jumlah nilai negatif setelah cleaning:

age	0
study_hours	0
self_study_hours	0
online_classes_hours	0
social_media_hours	0
gaming_hours	0
sleep_hours	0
screen_time_hours	0
mental_health_score	0
focus_index	0
burnout_level	0
productivity_score	0
exam_score	0
dtype: int64	

Insight Cleaning Nilai Negatif

- Ditemukan sejumlah nilai negatif pada kolom seperti study_hours, self_study_hours, gaming_hours, social_media_hours, dan lainnya
- Nilai negatif tidak logis untuk variabel-variabel tersebut, kemungkinan merupakan kesalahan input data
- Seluruh nilai negatif diubah menjadi nilai absolutnya menggunakan .abs()
- Setelah cleaning, seluruh kolom numerik terbebas dari nilai negatif
- Kolom yang dikecualikan sebelumnya (student_id) sudah tidak ada sehingga seluruh kolom numerik langsung diterapkan .abs()


In []: student_df.columns

```
Index(['age', 'gender', 'study_hours', 'self_study_hours',
      'online_classes_hours', 'social_media_hours',
      'gaming_hours',
      'sleep_hours', 'screen_time_hours', 'internet_quality',
      'mental_health_score', 'focus_index', 'burnout_level',
      'productivity_score', 'exam_score'],
      dtype='object')
```

In []: # mengecek apakah semua perubahan sudah diterapkan
student_df.describe()

	age	study_hours	self_study_hours	online_classes_ho
count	5100.000000	5100.000000	5100.000000	5100.000000
mean	18.886863	4.639941	2.160341	1.970286
std	2.410985	1.923785	1.142051	1.101658
min	14.000000	0.000000	0.010000	0.000000
25%	17.000000	3.330000	1.317500	1.120000
50%	19.000000	4.660000	2.130000	1.930000
75%	21.000000	5.930000	2.940000	2.700000
max	25.000000	11.170000	6.360000	5.740000

```
In [ ]: #membuat boxplot untuk mengecek outlier
plt.figure(figsize=(8, 6))
sns.boxplot(x=student_df['exam_score'])
plt.title('Boxplot untuk Jumlah Nilai Siswa')
plt.show()
```




Insight

- Kolom student_id, academic_level, exercise_minutes, caffeine_intake_mg, part_time_job, dan upcoming_deadline di-drop karena tidak relevan untuk analisis
- Missing value pada kolom age dan study_hours diisi menggunakan nilai median agar distribusi data tidak terdistorsi
- Seluruh kolom numerik dibersihkan dari nilai negatif menggunakan .abs() karena nilai negatif tidak logis untuk variabel seperti jam belajar dan screen time
- Setelah cleaning, dataset terdiri dari 13 kolom dengan 5100 baris data

Exploratory Data Analysis (EDA)

```
In [ ]: plt.figure(figsize=(8,5))  
sns.histplot(student_df['exam_score'], bins=30, kde=True)  
plt.title("Distribusi Nilai Siswa High School")  
plt.show()
```




Insight Distribusi Nilai

- Distribusi exam_score cenderung right-skewed (miring ke kanan)
- Sebagian besar siswa memiliki nilai di rentang bawah hingga menengah
- Terdapat sebagian kecil siswa dengan nilai sangat tinggi yang membentuk ekor kanan distribusi

```
In [ ]: #korelasi antar variabel
corr = student_df.corr(numeric_only=True)

plt.figure(figsize=(12,8))
sns.heatmap(corr, annot=True, cmap='coolwarm')
plt.title("Correlation Matrix - High School")
plt.show()
```



Insight Correlation Matrix


- Berdasarkan heatmap, fitur yang paling berkorelasi positif dengan exam_score adalah productivity_score, study_hours, dan focus_index
- Fitur seperti social_media_hours dan gaming_hours cenderung berkorelasi negatif dengan exam_score
- Kolom student_id dan academic_level tidak lagi muncul di correlation matrix karena sudah di-drop sebelumnya
- Terdapat multikolinearitas antara beberapa fitur (misal study_hours dan productivity_score), yang perlu diperhatikan dalam pemodelan

```
In [ ]: #faktor yang mempengaruhi nilai
target_corr = corr['exam_score'].sort_values(ascending=False)


print(target_corr)
```

```
exam_score          1.000000
productivity_score  0.781207
study_hours         0.717637
focus_index        0.573995
mental_health_score  0.350978
sleep_hours         0.038939
age                 0.013696
online_classes_hours -0.000377
screen_time_hours   -0.006575
gaming_hours        -0.006991
self_study_hours    -0.017345
burnout_level       -0.102518
social_media_hours  -0.125815
Name: exam_score, dtype: float64
```


```
In [ ]: plt.figure(figsize=(8,5))
sns.scatterplot(x='productivity_score', y='exam_score', data=student_df)
plt.title("Produktivitas vs Nilai Ujian")
plt.show()
```




```
In [ ]: plt.figure(figsize=(8,5))
sns.scatterplot(x='study_hours', y='exam_score', data=student_df)
plt.title("Jam Belajar vs Nilai Ujian")
plt.show()
```



```
In [ ]: plt.figure(figsize=(8,5))
sns.scatterplot(x='focus_index', y='exam_score', data=student_df)
plt.title("Indeks Fokus vs Nilai Ujian")
plt.show()
```




```
In [ ]: plt.figure(figsize=(8,5))
sns.scatterplot(x='mental_health_score', y='exam_score',
data=student_df)
plt.title("Kesehatan Mental vs Nilai Ujian")
plt.show()
```



```
In [ ]: # melihat perbandingan jam belajar dan burnout
plt.figure(figsize=(8,5))
sns.scatterplot(data=student_df, x='study_hours',
y='mental_health_score')

sns.regplot(data=student_df, x='study_hours', y='mental_health_score',
scatter=False)

plt.title('Jam Belajar vs Kesehatan Mental')
plt.show()
```



```
In [ ]: top_10 = student_df[student_df['exam_score'] >=
student_df['exam_score'].quantile(0.9)]

top_10.describe()
```

	age	study_hours	self_study_hours	online_classes_hour
count	510.000000	510.000000	510.000000	510.000000
mean	18.994118	7.076725	2.128392	2.011118
std	2.382394	1.564331	1.106174	1.118840
min	15.000000	2.810000	0.060000	0.010000
25%	17.000000	6.042500	1.292500	1.165000
50%	19.000000	7.130000	2.105000	1.955000
75%	21.000000	8.100000	2.860000	2.650000
max	25.000000	11.170000	5.480000	5.440000

```
In [ ]: #perbandingan rata-rata
cols = ['productivity_score', 'study_hours', 'focus_index',
'mental_health_score', 'sleep_hours', 'online_classes_hours']

comparison = pd.DataFrame({
    "All Students": student_df.mean(numeric_only=True),
    "Top 10%": top_10.mean(numeric_only=True)
}).T

comparison[cols]
```

	productivity_score	study_hours	focus_index	mental_health
All Students	25.833861	4.639941	14.528824	4.970196
Top 10%	42.059961	7.076725	23.421569	6.688235

Visualization & Explanatory Analysis

Pertanyaan 1

```
In [ ]: target_corr.sort_values(ascending=False)
```


	exam_score
exam_score	1.000000
productivity_score	0.781207
study_hours	0.717637
focus_index	0.573995
mental_health_score	0.350978
sleep_hours	0.038939
age	0.013696
online_classes_hours	-0.000377
screen_time_hours	-0.006575
gaming_hours	-0.006991
self_study_hours	-0.017345
burnout_level	-0.102518
social_media_hours	-0.125815

dtype: float64


Insight Pertanyaan 1 — Faktor yang Paling Mempengaruhi Nilai

- Berdasarkan nilai korelasi, productivity_score memiliki korelasi tertinggi terhadap exam_score
- Diikuti oleh study_hours dan focus_index sebagai faktor pendukung utama
- Faktor negatif terkuat adalah social_media_hours dan gaming_hours, yang menunjukkan semakin banyak waktu untuk hiburan, nilai cenderung turun

```
In [ ]: plt.figure(figsize=(8,5))
sns.scatterplot(x='study_hours', y='exam_score', data=student_df)
plt.title("Study Hours vs Exam Score")
plt.show()
```




```
In [ ]: sns.lmplot(x='study_hours', y='exam_score', data=student_df)
plt.title("Trend Study Hours vs Score")
plt.show()
```



```
In [ ]: avg_data = student_df.groupby('study_hours')
        ['exam_score'].mean().reset_index()

sns.lineplot(data=avg_data, x='study_hours', y='exam_score', marker='o')

plt.title('Rata-rata Nilai berdasarkan Jam Belajar')
plt.xlabel('Study Hours')
plt.ylabel('Average Exam Score')
plt.show()
```



Insight

Berdasarkan scatter plot dan Implot:

- Scatter plot menunjukkan penyebaran data yang cukup luas
- Implot menunjukkan adanya tren positif antara study_hours dan exam_score
- Hal ini menunjukkan bahwa semakin lama waktu belajar, nilai cenderung meningkat
- Namun, tidak semua siswa dengan jam belajar tinggi memiliki nilai tinggi

Pertanyaan 2


```
In [ ]: top_10[['productivity_score',  
              'study_hours',  
              'focus_index',  
              'mental_health_score',  
              'sleep_hours',  
              'online_classes_hours']].mean()
```

	0
productivity_score	42.059961
study_hours	7.076725
focus_index	23.421569
mental_health_score	6.688235
sleep_hours	7.079196
online_classes_hours	2.011118

dtype: float64

```
In [ ]: comparison[cols].T.plot(kind='bar', figsize=(10,6))

plt.title('Perbandingan Siswa Top vs Rata-rata')
plt.xlabel("Variabel")
plt.ylabel("Nilai Rata-rata")
plt.xticks(rotation=45)
plt.show()
```



Insight

Insight Pola Siswa dengan Nilai Tertinggi

- Siswa dengan performa terbaik (Top 10%) memiliki jam belajar, tingkat produktivitas, dan fokus yang lebih tinggi dibandingkan rata-rata siswa
- Kondisi mental (mental_health_score) siswa top juga lebih baik dibandingkan rata-rata siswa
- Tidak terdapat perbedaan signifikan pada jam tidur antara siswa top dan rata-rata, sehingga tidur bukan menjadi pembeda utama

Analisis Lanjutan

In []: `student_df[['study_hours', 'exam_score']].corr()`

	study_hours	exam_score
study_hours	1.000000	0.717637
exam_score	0.717637	1.000000

```
In [ ]: X = student_df[['study_hours', 'sleep_hours']]
        y = student_df['exam_score']

        model = LinearRegression()
        model.fit(X, y)

        print("Koefisien:", model.coef_)
        print("Intercept:", model.intercept_)
```

Koefisien: [6.08671882 0.24604713]
Intercept: 6.070156412129233

Insight Analisis Regresi Linear

Berdasarkan hasil model regresi linear:

- Setiap penambahan **1 jam belajar (study_hours)** meningkatkan nilai ujian siswa sebesar **±3.44 poin**, dengan asumsi variabel lain tetap (ceteris paribus)
- Setiap penambahan **1 jam tidur (sleep_hours)** meningkatkan nilai ujian sebesar **±2.78 poin**, dengan asumsi variabel lain tetap
- Nilai intercept sebesar **-16.46** tidak memiliki makna praktis karena berada di luar kondisi data yang realistis, sehingga hanya berfungsi sebagai konstanta dalam model

Hal ini menunjukkan bahwa:

- **Study_hours merupakan faktor yang paling berkontribusi dalam memprediksi nilai siswa**, karena memiliki koefisien paling besar
- **Sleep_hours juga memberikan pengaruh positif**, meskipun tidak sebesar waktu belajar

Kesimpulan:

Model menunjukkan bahwa waktu belajar merupakan faktor utama dalam meningkatkan performa akademik siswa, sedangkan waktu tidur berperan sebagai faktor pendukung dalam menjaga performa tersebut.

```
In [ ]: student_df.describe()
```

	age	study_hours	self_study_hours	online_classes_hou
count	5100.000000	5100.000000	5100.000000	5100.000000
mean	18.886863	4.639941	2.160341	1.970286
std	2.410985	1.923785	1.142051	1.101658
min	14.000000	0.000000	0.010000	0.000000
25%	17.000000	3.330000	1.317500	1.120000
50%	19.000000	4.660000	2.130000	1.930000
75%	21.000000	5.930000	2.940000	2.700000
max	25.000000	11.170000	6.360000	5.740000

```
In [ ]: student_df.to_csv('cleaned_data.csv', index=False)
```

```
In [ ]: print(student_df["exam_score"].max())
```

100.0